



تمرین پنجم

شماره دانشجویی: ۹۸۱۰۱۰۷۴

محمدجواد هزاره

سوال ۱

۱. در الگوریتم k-means خوشه‌ها به صورت دایروی خواهند بود در حالی که در الگوریتم EM حالت کلی‌ای برای خوشه‌ها فرض کرده‌ایم که با ماتریس Σ برای هر خوشه مشخص می‌شود. در این الگوریتم قیدی روی دایروی بودن خوشه‌ها نیست و خوشه‌ها به شکل بیضی فرض شده‌اند. علاوه بر آن، در الگوریتم EM داده‌ها به صورت soft به خوشه‌ها تخصیص داده می‌شوند، به این معنا که برای هر داده، به میزان اعتقادی که برای تعلق آن به خوشه k ام داریم، آن را در تعیین پارامترهای مدل k ام دخیل می‌کنیم. این دو الگوریتم می‌توانند عملکرد یکسانی داشته باشند به شرط آن‌که در اجرای EM، ماتریس کوواریانس مدل‌ها، Σ_k ها رابه صورت αI در نظر بگیریم که I ماتریس واحد است. با این کار خوشه‌ها در الگوریتم EM، مشابه الگوریتم k-means دایروی و با شعاع برابر خواهند شد.

۲. برای توزیع احتمال x_a به شرط x_b خواهیم داشت:

$$\begin{aligned} p(x_a|x_b) &= \frac{p(x_a, x_b)}{p(x_b)} \\ &= \frac{\sum_k \pi_k p(x_a, x_b|k)}{p(x_b)} \\ &= \sum_k \frac{\pi_k}{p(x_b)} p(x_b|k) p(x_a|x_b, k) \\ &= \sum_k \pi'_k p(x_a|x_b, k), \quad \pi'_k = \frac{\pi_k p(x_b|k)}{p(x_b)} \end{aligned}$$

که $p(x_b) = \sum_{x_a} p(x_a, x_b)$ و $p(x_b|k) = \sum_{x_a} p(x_a, x_b|k)$ بنابراین برای ضرایب داریم:

$$\pi'_k = \frac{\pi_k \sum_{x_a} p(x_a, x_b|k)}{\sum_{x_a} p(x_a, x_b)}$$

۳. مطابق الگوریتم، کران پایین درست‌نمایی به صورت زیر خواهد بود که k اندیس مربوط به خوشه‌ها و i اندیس

مربوط به داده‌هاست:

$$F(\theta, Q) = \sum_i \left[\sum_k Q_i^{(t)}(k) \log \left(\frac{p(x^{(i)}, k; \theta)}{Q_i^{(t)}(z)} \right) \right]$$

که $Q_i^{(t)}(z)$ پارامتر مربوط به داده‌ی i ام است که در مرحله‌ی t و E بدست آمده است. در واقع همان اعتقادی است که به عضویت داده‌ی i ام به خوشه‌ی z داریم. احتمال داده‌ی i ام و خوشه‌ی k به صورت زیر خواهد بود:

$$\begin{aligned} p(x^{(i)}, k; \theta) &= p(k) p(x^{(i)} | k) \\ &= \pi_k |2\pi\Sigma|^{-\frac{1}{2}} \exp \left(-\frac{1}{2} (x^{(i)} - \mu_k)^T \Sigma^{-1} (x^{(i)} - \mu_k) \right) \end{aligned}$$

بنابراین:

$$\begin{aligned} \theta^{(t+1)} &= \arg \max_{\theta} F(\theta, Q^{(t)}) \\ &= \arg \max_{\theta} \sum_i \left[\sum_k Q_i^{(t)}(k) \log p(x^{(i)}, k; \theta) \right] \\ &= \arg \max_{\theta} \sum_i \left[\sum_k Q_i^{(t)}(k) \left(\log \pi_k - \frac{d}{2} \log 2\pi + \frac{1}{2} \log |\Sigma^{-1}| - \frac{1}{2} (x^{(i)} - \mu_k)^T \Sigma^{-1} (x^{(i)} - \mu_k) \right) \right] \end{aligned}$$

که d بعد داده‌هاست. با توجه به رابطه‌ی بالا، جواب این معادله برای π_k ها و μ_k ها تفاوتی با روش معمول EM ندارد. اما برای پیدا کردن Σ داریم:

$$\begin{aligned} \frac{\partial f(\pi_k, \mu_k, \Sigma)}{\partial \Sigma} &= \frac{\partial f(\pi_k, \mu_k, \Sigma)}{\partial \Sigma^{-1}} \times \frac{\partial \Sigma^{-1}}{\partial \Sigma} \\ &= \frac{\partial \Sigma^{-1}}{\partial \Sigma} \sum_i \left[\sum_k Q_i^{(t)}(k) \left(\frac{1}{2} \Sigma^T - \frac{1}{2} (x^{(i)} - \mu_k)(x^{(i)} - \mu_k)^T \right) \right] \end{aligned}$$

با صفر قرار دادن رابطه‌ی بالا به ازای $\hat{\Sigma}$ و $\hat{\mu}_k$ ها و توجه به این نکته که ماتریس کوواریانس ماتریسی متقارن است، خواهیم داشت: (که $\hat{\mu}_k$ تخمین μ_k ها در همین مرحله و N تعداد کل داده‌ها است.)

$$\begin{aligned} \frac{\partial \Sigma^{-1}}{\partial \Sigma} \sum_i \left[\sum_k Q_i^{(t)}(k) \left(\frac{1}{2} \hat{\Sigma}^T - \frac{1}{2} (x^{(i)} - \hat{\mu}_k)(x^{(i)} - \hat{\mu}_k)^T \right) \right] &= 0 \\ \Rightarrow \sum_i \left[\hat{\Sigma}^T - \sum_k Q_i^{(t)}(k) (x^{(i)} - \hat{\mu}_k)(x^{(i)} - \hat{\mu}_k)^T \right] &= 0 \\ \Rightarrow \hat{\Sigma} &= \frac{1}{N} \sum_i \left[\sum_k Q_i^{(t)}(k) (x^{(i)} - \hat{\mu}_k)(x^{(i)} - \hat{\mu}_k)^T \right] \end{aligned}$$

سوال ۲

۱. داده‌های مسئله را $\mathcal{D} = \{x^{(i)}\}_{i=1}^N$ در نظر می‌گیریم که $x^{(i)} \in \mathbb{N}$. بنابراین کران پایین درست‌نمایی برابر خواهد بود با:

$$F(\theta, Q) = \sum_i \left[\sum_k Q_i(k) \log \left(\frac{p(x^{(i)}, k; \theta)}{Q_i(k)} \right) \right]$$

مطابق الگوریتم EM، در مرحله‌ی E با استفاده از پارامترها تا این لحظه، تابع F را با ثابت نگه داشتن θ ، نسبت به Q بیشینه می‌کنیم. بنابراین در مرحله‌ی E داریم:

$$Q_i^{(t)} = \arg \max_Q F(\theta^{(t)}, Q)$$

که جواب این بهینه‌سازی برابر با احتمال شرطی z به شرط دیدن داده‌ی i ام است. یا به عبارتی:

$$Q_i^{(t)}(z) = p(z|x^{(i)}; \theta^{(t)})$$

که برای این مسئله داریم:

$$Q_i^{(t)}(k) = \frac{p(k, x^{(i)}; \theta^{(t)})}{p(x^{(i)}; \theta^{(t)})} = \frac{\pi_k e^{-\theta_k} \frac{\theta_k^{x^{(i)}}}{x^{(i)}!}}{\sum_j \pi_j e^{-\theta_j} \frac{\theta_j^{x^{(i)}}}{x^{(i)}!}}$$

که پارامترهای θ_k از $\theta^{(t)}$ آمده اند که برای جلوگیری از شلوغ شدن رابطه، $\theta^{(t)}$ برای آن‌ها نیامده است.

سپس در مرحله‌ی M با استفاده از رابطه‌ی بدست آمده برای Q ، تابع F را با ثابت نگه داشتن Q نسبت به θ بیشینه می‌کنیم. بنابراین:

$$\begin{aligned} \theta^{(t+1)} &= \arg \max_{\theta} F(\theta, Q^{(t)}) \\ &= \arg \max_{\theta} \sum_i \left[\sum_k Q_i^{(t)}(k) \log p(x^{(i)}, k; \theta) \right] \end{aligned}$$

برای احتمال مشترک نیز داریم:

$$p(x^{(i)}, k; \theta) = \pi_k e^{-\theta_k} \frac{\theta_k^{x^{(i)}}}{x^{(i)}!}$$

بنابراین:

$$\theta^{(t+1)} = \arg \max_{\theta} \sum_i \left[\sum_k Q_i^{(t)}(k) (\log \pi_k - \theta_k + x^{(i)} \log \theta_k) \right]$$

همچنین می‌دانیم که $\sum_k \pi_k = 1$. بنابراین از روش ضرایب لاگرانژ استفاده می‌کنیم. برای لاگرانژ داریم:

$$L(\boldsymbol{\pi}, \boldsymbol{\theta}, \lambda) = \sum_i \left[\sum_k Q_i^{(t)}(k) (\log \pi_k - \theta_k + x^{(i)} \log \theta_k) \right] - \lambda (\sum_k \pi_k - 1)$$

برای مشتق‌ها خواهیم داشت:

$$\begin{cases} \frac{\partial L}{\partial \pi_j} = \sum_i \left[Q_i^{(t)}(j) \frac{1}{\pi_j} \right] - \lambda \\ \frac{\partial L}{\partial \theta_j} = \sum_i \left[Q_i^{(t)}(j) \left(-1 + \frac{x^{(i)}}{\theta_j} \right) \right] \\ \frac{\partial L}{\partial \lambda} = \sum_k \pi_k - 1 \end{cases}$$

که با صفر قرار دادن روابط بالا به ازای $\theta_j^{(t+1)}$ و $\pi_j^{(t+1)}$ ، به نتایج زیر می‌رسیم:

$$\begin{cases} \pi_k^{(t+1)} = \frac{\sum_i Q_i^{(t)}(k)}{\sum_j \sum_i Q_i^{(t)}(j)} = \frac{\sum_i Q_i^{(t)}(k)}{N} \\ \theta_k^{(t+1)} = \frac{\sum_i x^{(i)} Q_i^{(t)}(k)}{\sum_i Q_i^{(t)}(k)} \end{cases}$$

۲. در این قسمت می‌خواهیم بهینه‌سازی‌ای که در قسمت قبل و در مرحله‌ی E استفاده کردیم را اثبات کنیم. در واقع می‌خواهیم نشان دهیم جواب بهینه‌سازی $\arg \max_Q F(\theta^{(t)}, Q)$ به صورت $Q_i^{(t)}(z) = p(z|x^{(i)}; \theta^{(t)})$ است. برای این منظور داریم:

$$Q^{(t)} = \arg \max_Q \sum_i \left[\sum_k Q_i(k) (\log p(x^{(i)}, k; \theta^{(t)}) - \log Q_i(k)) \right]$$

همچنین برای هر i قیدی به صورت $\sum_k Q_i(k) = 1$ داریم. بنابراین برای بهینه‌سازی از روش ضرایب لاگرانژ استفاده می‌کنیم. لاگرانژ به صورت زیر خواهد بود:

$$L(Q, \boldsymbol{\lambda}) = \sum_i \left[\sum_k Q_i(k) (\log p(x^{(i)}, k; \theta^{(t)}) - \log Q_i(k)) \right] - \sum_i \left[\lambda_i \left(\sum_k Q_i(k) - 1 \right) \right]$$

برای حل این بهینه‌سازی، باید دقت کنیم که Q_i ها تابع هستند. اما برای حل می‌توان آن‌ها را به صورت سطریهای یک ماتریس در نظر گرفت چرا که دامنه‌ی k گسسته و محدود است. اگر N تعداد داده‌ها و K تعداد خوشه‌ها باشد، ماتریس $A_{N \times K}$ را به این صورت که $A_{ij} = Q_i(j)$ در نظر می‌گیریم. هدف پیدا کردن درایه‌های این

ماتریس خواهد بود. بنابراین:

$$L(A, \lambda) = \sum_i \left[\sum_k A_{ik} (\log p(x^{(i)}, k; \theta^{(t)}) - \log A_{ik}) \right] - \sum_i \left[\lambda_i \left(\sum_k A_{ik} - 1 \right) \right]$$

برای مشتق‌ها خواهیم داشت:

$$\begin{cases} \frac{\partial L}{\partial A_{ij}} = \log p(x^{(i)}, j; \theta^{(t)}) - \log A_{ij} - 1 - \lambda_i \\ \frac{\partial L}{\partial \lambda_i} = \sum_j A_{ij} - 1 \end{cases}$$

با صفر قرار دادن روابط بالا به ازای A_{ij}^* و λ_i^* خواهیم داشت:

$$\begin{cases} (1) \quad \log p(x^{(i)}, j; \theta^{(t)}) - \log A_{ij}^* - 1 - \lambda_i^* = 0 \\ (2) \quad \sum_j A_{ij}^* - 1 = 0 \end{cases}$$

با حل رابطه‌ی (1) برای A_{ij}^* بر حسب λ_i^* به نتیجه‌ی زیر می‌رسیم:

$$A_{ij}^* = p(x^{(i)}, j; \theta^{(t)}) e^{-(1+\lambda_i^*)}$$

با قرار دادن این رابطه در معادله‌ی (2) ادامه می‌دهیم:

$$e^{-(1+\lambda_i^*)} \sum_j p(x^{(i)}, j; \theta^{(t)}) = 1 \implies 1 + \lambda_i^* = \log p(x^{(i)}; \theta^{(t)})$$

حال این نتیجه را در معادله‌ی (1) قرار می‌دهیم:

$$\log p(x^{(i)}, j; \theta^{(t)}) - \log A_{ij}^* - \log p(x^{(i)}; \theta^{(t)}) = 0$$

$$\implies \log \left(\frac{p(x^{(i)}, j; \theta^{(t)})}{A_{ij}^* p(x^{(i)}; \theta^{(t)})} \right) = 0$$

$$\implies A_{ij}^* = \frac{p(x^{(i)}, j; \theta^{(t)})}{p(x^{(i)}; \theta^{(t)})}$$

$$\implies \boxed{A_{ij}^* = p(j|x^{(i)}; \theta^{(t)})}$$

بنابراین با توجه به تعریف A ، داریم $Q_i^{(t)}(k) = p(k|x^{(i)}; \theta^{(t)})$ و خواسته‌ی مسئله اثبات می‌شود.

سوال ۳

۱. احتمال این که w_t برد در روز t داشته باشیم به شرط آن که بدانیم در این روز در کل m_t بازی انجام شده و بازیکن k ام بازی می کرده است، با فرض این که نتیجه بازی ها از یکدیگر مستقل بوده و بازیکن k ام با احتمال p_k بازی خود را می برد، برابر خواهد بود با:

$$w_t | m_t, k \sim \text{Bin}(m_t, p_k) \implies p(w_t | m_t, k) = \binom{m_t}{w_t} p_k^{w_t} (1 - p_k)^{m_t - w_t}$$

برای احتمال این که w_t برد داشته باشیم به شرط آن که بدانیم در این روز تعداد m_t بازی صورت گرفته، برابر خواهد بود با:

$$\begin{aligned} p(w_t | m_t) &= \sum_k p(w_t, k | m_t) \\ &= \sum_k p(k | m_t) p(w_t | k, m_t) \\ &= \sum_k \pi_k \binom{m_t}{w_t} p_k^{w_t} (1 - p_k)^{m_t - w_t} \end{aligned}$$

۲. می دانیم در مرحله ی E، مقدار Q به صورت $Q_t^{(i)}(z_t) = p(z_t | x_t; \theta^{(i-1)})$ آپدیت می شود. بنابراین در این مسئله داریم:

$$\begin{aligned} Q_t^{(i)}[k] &= p(k | w_t, m_t; \theta^{(i-1)}) \\ &= \frac{p(k, w_t, m_t)}{p(w_t, m_t)} \\ &= \frac{p(k) p(m_t | k) p(w_t | m_t, k)}{p(m_t) p(w_t | m_t)} \\ &= \frac{\pi_k^{(i-1)} \binom{m_t}{w_t} \left(p_k^{(i-1)}\right)^{w_t} \left(1 - p_k^{(i-1)}\right)^{m_t - w_t}}{\sum_j \pi_j^{(i-1)} \binom{m_t}{w_t} \left(p_j^{(i-1)}\right)^{w_t} \left(1 - p_j^{(i-1)}\right)^{m_t - w_t}} \end{aligned}$$

که با توجه به مستقل بودن m_t از k ، $p(m_t | k)$ از صورت $p(m_t)$ از مخرج ساده شده است.

۳. اگر کران پایین درست نمایی را با $F(\theta, Q)$ نشان دهیم، آنگاه خواهیم داشت:

$$F(\theta, Q) = \sum_t \left[\sum_k Q_t[k] \log \left(\frac{p(x_t, k; \theta)}{Q_t[k]} \right) \right]$$

حال برای پیدا کردن بیشینه ی این تابع به روش الگوریتم EM، باید Q را ثابت و برابر مقدار به دست آمده در مرحله ی

E در نظر گرفت و سپس F را نسبت به θ بیشینه کنیم. بنابراین:

$$\begin{aligned}\theta^{(i)} &= \arg \max_{\theta} F(\theta, Q^{(i)}) \\ &= \arg \max_{\theta} \sum_t \left[\sum_k Q_t^{(i)}[k] \left(\log p(x_t, k; \theta) - \log Q_t^{(i)}[k] \right) \right] \\ &= \arg \max_{\theta} \sum_t \left[\sum_k Q_t^{(i)}[k] \log p(x_t, k; \theta) \right]\end{aligned}$$

برای احتمال داده‌ی t ام نیز داریم:

$$\begin{aligned}p(w_t, m_t, k; \theta) &= p(k) p(m_t|k) p(w_t|m_t, k) \\ &= \pi_k \binom{m_t}{w_t} p_k^{w_t} (1 - p_k)^{m_t - w_t} p(m_t|k)\end{aligned}$$

با جایگذاری این رابطه در رابطه‌ی مربوط به t و در نظر گرفتن این موضوع که $p(m_t|k)$ مستقل (از لحاظ تابع، نه از لحاظ احتمالاتی) از θ است، خواهیم داشت:

$$\theta^{(i)} = \arg \max_{\pi_k, p_k} \sum_t \left[\sum_k Q_t^{(i)}[k] (\log \pi_k + w_t \log p_k + (m_t - w_t) \log(1 - p_k)) \right]$$

برای پیدا کردن $p_j^{(i)}$ کافیست از رابطه‌ی بالا مشتق گرفته و برابر صفر قرار دهیم. بنابراین:

$$\frac{\partial f(\pi_k, p_k)}{\partial p_j} = \sum_t \left[Q_t^{(i)}[j] \left(\frac{w_t}{p_j} - \frac{(m_t - w_t)}{1 - p_j} \right) \right]$$

و با صفر قرار دادن رابطه‌ی بالا به ازای $p_j^{(i)}$ به نتیجه‌ی زیر می‌رسیم:

$$\boxed{p_j^{(i)} = \frac{\sum_{t=1}^n Q_t^{(i)}[j] w_t}{\sum_{t=1}^n Q_t^{(i)}[j] m_t}}$$

سوال ۴

۱. لگاریتم احتمال پسین به صورت زیر به احتمال پیشین پارامتر و درست‌نمایی بستگی خواهد داشت:

$$\log p(\theta|X) = \log p(\theta) + \log p(X|\theta) + Const$$

بنابراین θ ای که احتمال پیشین را بیشینه کند، عبارت سمت راست را نیز بیشینه خواهد کرد. هدف حل مسئله‌ی زیر است:

$$\theta^* = \arg \max_{\theta} (\log p(\theta) + \log p(X|\theta))$$

برای حل این مسئله به روش EM، نخست کران پایینی روی تابع هدف پیدا می‌کنیم. برای این کار تابع زیر را ارائه می‌کنیم:

$$\bar{F}(\theta, Q) = F(\theta, Q) + \log p(\theta)$$

که F همان تابعی است که در روش MLE استفاده می‌کردیم و برابر با:

$$F(\theta, Q) = \sum_i \left[\sum_k Q_i(k) \log \left(\frac{p(x^{(i)}, k; \theta)}{Q_i(k)} \right) \right]$$

اثبات کران پایین بودن تابع ارائه شده نیز سر راست است. برای F که با توجه به محاسبات قبلی و نامساوی Jensen می‌دانیم $F(\theta, Q) \geq \log p(X|\theta)$ ، و با اضافه کردن $\log p(\theta)$ به دو طرف نامعادله نیز به نتیجه‌ی خواسته شده یعنی $\bar{F}(\theta, Q) \geq \log p(X|\theta) + \log p(\theta) = \log p(\theta|X)$ می‌رسیم. بنابراین مراحل الگوریتم EM به صورت زیر خواهد بود:

$$E : Q^{(t)} = \arg \max_Q \bar{F}(\theta^{(t)}, Q) = \arg \max_Q F(\theta^{(t)}, Q)$$

$$M : \theta^{(t+1)} = \arg \max_{\theta} \bar{F}(\theta, Q^{(t)})$$

که در تساوی دوم مرحله‌ی E، از استقلال جبری $\log p(\theta)$ از Q استفاده شده است.

۲. داده‌ی ورودی مسئله را به صورت (n_b, n_d) در نظر می‌گیریم. متغیر نهان مسئله نیز همان n_a خواهد بود. با مشخص شدن این سه متغیر مقدار n_c از روی معادله‌ی $n_a + n_b + n_c + n_d = n$ مشخص خواهد شد. یک سمپل در این مسئله برابر با یک دوتایی (n_b, n_d) خواهد بود. بنابراین در این نمونه از مسئله‌ی داده شده فقط یک سمپل داریم. (بنابراین اندیس‌های i را می‌توان از تمام معادلات حذف کرد.) برای احتمال دیدن n_a ، n_b ، n_c و n_d خواهیم

داشت:

$$p(n_a, n_b, n_c, n_d; \theta) = \frac{n!}{n_a!n_b!n_c!n_d!} \left(\frac{1}{3}\right)^{n_a} \left(\frac{1}{3}(1-\theta)\right)^{n_b} \left(\frac{2}{3}\theta\right)^{n_c} \left(\frac{1}{3}(1-\theta)\right)^{n_d}$$

با توجه به قسمت اول سوال، برای مرحله ی E داریم:

$$Q^{(t)} = \arg \max_Q \sum_k Q(k) \log \left(\frac{p(n_b, n_d, n_a = k; \theta)}{Q(k)} \right)$$

که حل این معادله مشابه قبل بوده و جواب آن برابر $p(n_a = k | n_b, n_d; \theta^{(t)})$ خواهد بود. بنابراین:

$$\begin{aligned} Q^{(t)} &= p(n_a = k | n_b, n_d; \theta^{(t)}) \\ &= \frac{p(n_a = k, n_b, n_d)}{\sum_j p(n_a = j, n_b, n_d)} \\ &= \frac{\frac{n!}{k!n_b!n_c!n_d!} 3^{-n} (1-\theta)^{n_b+n_d} (2\theta)^{n_c}}{\sum_j \frac{n!}{j!n_b!n_c!n_d!} 3^{-n} (1-\theta)^{n_b+n_d} (2\theta)^{n_c}}, \quad n_c = n - (n_a + n_b + n_d) \end{aligned}$$

برای مرحله ی M خواهیم داشت:

$$\begin{aligned} \theta^{(t+1)} &= \arg \max_{\theta} \log p(\theta) + \sum_k Q^{(t)}(k) \log \left(\frac{p(n_b, n_d, n_a = k; \theta)}{Q^{(t)}(k)} \right) \\ &= \arg \max_{\theta} \log p(\theta) + \sum_k Q^{(t)}(k) \log p(n_b, n_d, n_a = k; \theta) \\ &= \arg \max_{\theta} (v_1 - 1) \log \theta + (v_2 - 1) \log(1 - \theta) + \sum_k Q^{(t)}(k) [(n_b + n_d) \log(1 - \theta) + n_c \log \theta] \end{aligned}$$

برای حل این بهینه سازی نیز کافیت نسبت به θ مشتق گرفته و برابر صفر قرار دهیم. بنابراین:

$$\begin{aligned} \frac{df}{d\theta} &= \frac{v_1 - 1}{\theta} - \frac{v_2 - 1}{1 - \theta} + \sum_k Q^{(t)}(k) \left(\frac{n_c}{\theta} - \frac{n_b + n_d}{1 - \theta} \right) \\ &= \frac{v_1 - 1}{\theta} - \frac{v_2 - 1}{1 - \theta} - \frac{n_b + n_d}{1 - \theta} + \sum_k Q^{(t)}(k) \frac{n - n_b - n_d - k}{\theta} \\ &= \frac{v_1 - 1 + n - n_b - n_d - \sum_k k Q^{(t)}(k)}{\theta} - \frac{v_2 - 1 + n_b + n_d}{1 - \theta} \end{aligned}$$

با صفر قرار دادن رابطه‌ی بالا برای $\theta^{(t+1)}$ خواهیم داشت:

$$\theta^{(t+1)} = \frac{(v_1 - 1) + (n - n_b - n_d) - \sum_k k Q^{(t)}(k)}{(v_1 + v_2 - 2) + n - \sum_k k Q^{(t)}(k)}$$